

增强棋类强化学习的图表示方法

Tomas Rigaux*
京都大学
tomas@i.kyoto-u.ac.jp
rigaux.com

Hisashi Kashima
京都大学
Kyoto University 京都, 日本
kashima@i.kyoto-u.ac.jp

摘要

掌握游戏是一项艰巨的任务，因为游戏可以极其复杂，并且在结构上彼此之间仍然存在根本性的不同。虽然AlphaZero算法展示了其学习各种游戏规则和策略的强大能力，从围棋和国际象棋到Atari游戏，但其对大量计算资源和刚性的卷积神经网络（CNN）架构的依赖限制了其适应性和可扩展性。一个训练用于在19×19围棋棋盘上玩游戏的模型不能用于在较小的13×13棋盘上玩游戏，尽管这两种围棋变体之间存在相似性。在本文中，我们专注于国际象棋，并探索使用基于图的游戏状态表示，而不是基于网格的表示，以引入基于图神经网络（GNN）的更通用架构。我们还将经典的图注意力网络（GAT）层扩展为包含边特征，以自然地提供通用的策略输出格式。我们在比初始AlphaZero论文中更小的网络上进行的实验表明，这种新架构在参数数量相似的情况下表现出色，能够比以前的架构快一个数量级地提高游戏实力。我们还展示了当模型在较小的5×5国际象棋变体上进行训练时，能够快速微调以在标准8×8国际象棋上玩游戏，这表明这种方法具有令人鼓舞的泛化能力。我们的代码可在<https://github.com/akulen/AlphaGateau>获取。

1 介绍

在过去的十年里，将强化学习（RL）与深度神经网络（DNNs）相结合，已被证明是设计广泛游戏的游戏代理的一种强大方式。值得注意的成就包括AlphaGo在围棋中的主导地位[17]，AlphaZero在国际象棋和将棋中的人类风格的游戏方式[18]，以及MuZero在各种Atari游戏中的熟练程度[15]。它们使用自我对弈和蒙特卡洛树搜索（MCTS）[6]来逐步提高其性能，这种方式类似于人类通过经验、直觉和游戏树探索来学习的方式。

Previous attempts to制作基于RL的国际象棋引擎是不成功的，因为MCTS探索需要一个精确的位置启发式来引导其探索。传统的手工启发式，如在彻底搜索树搜索中使用的启发式过于简单，缺乏MCTS随机树探索所期望的复杂程度，以更准确地评估复杂的国际象棋位置。通过结合计算能力的进步与深度学习领域的进展，AlphaZero能够提供一种适当的形式，即深度神经网络启发式，在这种启发式与MCTS算法共生学习的过程中，逐步提高自身。

*tomas.rigaux.com

然而，这些方法依赖于刚性的、针对特定游戏的神经网络架构，通常使用基于网格的数据结构表示游戏状态，并使用卷积神经网络（CNNs）处理这些数据，这限制了它们的灵活性和泛化能力。例如，一个在标准 19×19 围棋棋盘上训练的模型，如果不进行其内部结构的重大修改、手动参数转移和重新训练，很难适应在较小的 13×13 棋盘上进行游戏，尽管这些游戏的基本游戏动态相似。这种不灵活性进一步受到从头开始为每个特定游戏或棋盘配置训练这些大规模模型所需大量计算资源的影响。如果有可能训练一个单一模型来学习各种游戏的不同变体，甚至同时学习多种游戏，那么通过先在简化且较小的变体游戏中学习基本规则，然后再向模型呈现更复杂的版本，可以加快训练速度。同样，如果一个模型学会了国际象棋的所有规则，它就可以作为一个强大的起点来学习将棋的规则，例如。

它可以设计一种更通用的游戏架构，例如围棋，其中移动可以一对一地映射到棋盘网格，这样模型仍然可以使用CNN层并同时处理不同大小的棋盘，但在移动变得更加复杂时，包括在不同方格之间移动棋子，甚至在将捕获的棋子重新放回棋盘上时，这种解决方案就不再可行了。

那些动作唤起了一种图状结构，其中棋子最初位于方格上，然后按照连接这两个方格的边或节点移动到不同的新方格。因此，自然地考虑基于图表示而不是网格表示建立改进的模型。我们探索用GNN层替换CNN层来实现这一想法，并且在本文中特别考虑基于注意力的GNN层，反映棋手通常如何记住棋子形成的结构以及它们之间的相互作用，而不是记住每个单独棋子的位置。

表示移动作为图中的边也可以引入将输出策略大小与边的数量联系起来的可能性，从而使模型能够同时处理具有不同移动结构的不同游戏变体。为此，除了节点特征外，还需要边特征，因为这些特征将用于计算每条边的等效移动概率。与经典的注意力GNN层——图注意力网络（GAT）[19]仅定义和更新节点特征不同，我们提出了一种新的GAT层的修改版本，我们称之为图注意力网络从注意力权重更新中获取边特征（GATEAU），以引入边特征。我们还描述了包含GATEAU层的完整模型架构，该架构可以处理不同大小的输入图，类似于AlphaGateau。

我们的实验结果表明，与原始AlphaZero相比，使用较小网络实现的新架构在具有相似数量参数的情况下表现出更优的性能。AlphaGateau展示了显著更快的学习速度，在极短的训练时间内实现了显著的棋力提升。此外，我们的方法展示了良好的泛化能力：在较小的 5×5 变体国际象棋上训练的模型可以快速微调以在标准 8×8 国际象棋棋盘上进行游戏，并且在较少的计算资源消耗下达到竞争力的性能。

2 相关工作

强化学习。AlphaGo [17]、AlphaZero [18]、MuZero [15] 以及其他方法引入了一种强大的框架，利用强化学习技术生成自对弈数据，用于从头训练一个神经网络来玩棋类游戏。

然而，这些框架使用的是刚性的神经网络，这些网络需要针对一个特定的游戏进行专门化。因此，训练过程需要大量的计算资源。此外，一种类型的游戏的训练无法重用于另一种类型的游戏，也无法先在游戏的较小和较简单的变体上开始训练，然后再引入更多复杂性。

可扩展的AlphaZero。在Ben-Assayag和El-Yaniv [2]的研究中，使用图神经网络已被探索作为一种解决这些问题的方法。基于GNN的模型使得能够输入不同大小的样本，例如大小在5到16之间的Othello棋盘，从而使模型能够学习如何在游戏的简化版本中进行游戏。

表 1: 节点特征

Dimensions	Description
12	The piece on the square, as a 12-dimensional soft one-hot
2	Whether the position was repeated before
98	For each of the previous 7 moves, we repeat the last 14 dimensions to describe the corresponding positions
1	The current player
1	The total move count
4	Castling rights for each player
1	The number of moves with no progress

Table 2: Edge features

Dimensions	Description
1	Is this move legal in the current position?
2	How many squares {to the left/up} does this edge move?
4	Would a pawn promote to a {knight/bishop/rook/queen} if it did this move?
2	Could a {white/black} pawn do this move?
4	Could a {knight/bishop/rook/queen} do this move?
2	Could a {white/black} king do this move?

都需要节点和边特征。本文将介绍 GATEAU 层，这是 GAT 层 [19] 对边特征的自然扩展。

4.2 图设计

在 AlphaZero 中，一个国际象棋位置被编码为一个 $n \times n \times 119$ 矩阵，其中每个棋盘上的 $n \times n$ 方格关联到一个大小为 119 的特征向量，包含当前位置以及过去 7 个位置的对应方格信息，如表 1 所述。

我们将棋盘状态表示为一个图 $G(V, E)$ ，其中 $n \times n$ 个方格是节点 V ，边 E 表示移动，基于 AlphaZero 的动作设计。每个 AlphaZero 动作是一对（起始方格，移动），有 $n \times n$ 个可能的起始方格。在 8×8 国际象棋中，73 个移动（分别在 5×5 国际象棋中有 49 个）被分为 56 个皇后移动（分别有 32 个），8 个骑士移动（分别有 8 个），以及 9 个升变（分别有 9 个），总共 4672 个动作（分别有 1225 个）。与一个动作相关的边是从对应起始方格的节点指向关联移动的目的方格。在 8×8 国际象棋中，王车易位用一个动作从国王的起始方格横向移动 2 格来表示。由于这种动作编码稍微太大，包含了一些结束于棋盘外且不对应真实边的实际移动，因此构建的图只包含 1858 条边（分别有 455 条），仅对应于有效的移动。

节点和边特征，初始大小分别为 119 和 15，分别详细列于表 1 和表 2。节点特征基于 AlphaZero 的特征，包括棋子类型、游戏状态信息和历史走法数据。边特征编码了走法合法性、方向、潜在的升变以及棋子特定的走法能力。在 5×5 国际象棋的情况下，我们包括未使用的易位信息，以使向量大小与 8×8 模型相同。对于不同的游戏或变体，可以预先处理节点和边特征，但为了简化，我们没有这样做。

在我们实验中所有游戏的起始位置要么是标准的 8×8 国际象棋布局，要么是 5×5 加德纳棋的布局，如图 1 所示。

4.3 GATEAU: 一种新的 GNN 层，带有边特征

The Graph Attention Network 层由 Veličković 等人 [19] 引入，通过加权平均邻节点特征来更新节点特征。更准确地说，给定节点特征 $h \in \mathbb{R}^{N \times K}$ ，加权系数定义为

$$e_{ij} = W_u h_i + W_v h_j \quad (1)$$

带有参数 $W_u, W_v \in \mathbb{R}^{K \times K'}$ 。在原始论文中， $W_u = W_v$ ，但由于我们处理的是有向图，我们对它们进行了区分以不对称地处理源节点和目标节点。然后

我们可以计算注意力权重 α ，并使用它们来更新节点特征：

$$\alpha_{ij}^0 = \text{softmax}_j(\text{LeakyReLU}(a^T e_{ij})) = \frac{\exp^{\text{LeakyReLU}(a^T e_{ij})}}{\sum_k \exp^{\text{LeakyReLU}(a^T e_{ik})}}, \quad (2)$$

$$h'_i = \sum_{j \in \mathcal{N}_i} \alpha_{ij}^0 W h_j \quad (3)$$

带有参数 $W \in \mathbb{R}^{K \times K''}$ 和 $a \in \mathbb{R}^{K'}$ 。

The main observation motivating GATEAU is that in this process, the attention coefficients e_{ij} serve a role similar to node features, being a vector encoding some information between nodes i and j . As such, we propose to introduce edge features in place of those attention coefficients.

我们提出的层称为Graph Attention neTwork with Edge features from Attention weight Updates (GATEAU)，它以节点特征 $h \in \mathbb{R}^{N \times K}$ 和边特征 $g_{i,j} \in \mathbb{R}^{N \times N \times K'}$ 作为输入。我们首先像等式1那样简单地更新边特征：

$$g'_{ij} = W_u h_i + W_e g_{ij} + W_v h_j \quad (4)$$

带有参数 $W_u, W_v \in \mathbb{R}^{K \times K'}$ 和 $W_e \in \mathbb{R}^{K' \times K'}$ 。然后通过用我们的新边特征替换注意力系数来获得注意力权重，如 Eq. 2 所示：

$$\alpha_{ij} = \text{softmax}_j(\text{LeakyReLU}(a^T g'_{ij})) \quad (5)$$

带有参数 $a \in \mathbb{R}^{K'}$ 。最后，我们更新节点特征如公式 3 所示：

$$h'_i = W_0 h_i + \sum_{j \in \mathcal{N}_i} \alpha_{ij} (W_h h_j + W_g g_{ij}) \quad (6)$$

带有参数 $W_0, W_h \in \mathbb{R}^{K \times K''}$ 和 $W_g \in \mathbb{R}^{K' \times K''}$ 。我们手动添加自边，因为在图中包含自边会给策略头带来不便，我们会将边特征的值重新混合到节点特征中。

4.4 AlphaGateau: 一个基于AlphaZero和GATEAU的完整模型架构

遵循AlphaZero神经网络的结构，我们引入AlphaGateau，将AlphaZero与GATEAU结合替代CNN层，并重新设计价值头和策略头，分别利用节点和边特征以处理任意大小的输入同时保持相同数量的参数。

我们定义了以下层，用于描述图2中的AlphaGateau。

Attention 汇聚。为了计算给定图的价值，我们需要将特征聚合起来。节点特征似乎与位置信息更相关，所以我们使用节点特征 $h \in \mathbb{R}^{N \times K}$ 而不是边特征 $a \in \mathbb{R}^K$ 进行汇聚。为此，我们使用一种基于注意力的汇聚层，类似于 Li 等人 [14] 在 Eq. 7 中描述的，该层对于节点特征 $h \in \mathbb{R}^{N \times K}$ 和一个参数向量 $a \in \mathbb{R}^K$ ，输出

$$\alpha_i^p = \text{softmax}_i(\text{LeakyReLU}(a^T h_i)), \quad H = \sum_i \alpha_i^p h_i, \quad (7)$$




图 1: 8×8 和 5×5 棋局的起始位置




图 2: AlphaGateau 网络, hs 是特征向量的内尺寸, L 是残差块的数量。




Figure 3: Value head




图4: 策略头

where $H \in \mathbb{R}^K$ 是全局特征向量。

批标准化和非线性 (BNR)。由于它们是一对经常同时出现的操作, 我们将批标准化和ReLU层组合在一起, 用BNR表示:

$$\text{BNR}(x) = \text{ReLU}(\text{BatchNorm}(x)). \quad (8)$$

Residual GATEAU (ResGATEAU). 类似于AlphaZero的残差块架构, 我们引入了ResGATEAU, 它同样将两个堆叠的GATEAU层的归一化输出与输入相加:

$$\text{ResGATEAU}(h, g) = (h, g) + \text{GATEAU}(\text{BNR}(\text{GATEAU}(\text{BNR}(h, g)))). \quad (9)$$

5 实验

我们评估了AlphaGateau从头学习标准8×8国际象棋以及从5×5变体泛化到标准8×8棋盘的性能。用于评估模型的指标是Elo等级分, 通过与其他具有相似等级分的模型 (或玩家) 进行对局来计算。由于计算资源的限制, 我们无法复制初始AlphaZero论文中使用的全部40个残差层, 并尝试了5层和6层模型。我们还开始探索8层模型, 但这些模型需要生成更多的数据, 这会使实验运行时间增加一个数量级。我们的结果显示, AlphaGateau比具有相似结构和深度的传统CNN模型学习速度快得多, 并且可以从5×5棋盘高效地微调到8×8棋盘, 通过较少的训练迭代就能达到竞争力的性能。²这些实验中使用的所有模型都是使用Adam优化器[12]

(学习率为0.001) 训练的。所有特征向量的嵌入维度为128。损失函数与原始AlphaZero相同, 即对于 $f_\theta(s) = \tilde{\pi}, \tilde{v}$,

$$L(\pi, v, \tilde{\pi}, \tilde{v}) = -\pi^T \log(\tilde{\pi}) + (v - \tilde{v})^2. \quad (10)$$

²In Silver et al.[18], the training of AlphaZero is described in terms of steps, which consists of one mini-batch of size 4096, while the generation of games through self-play is done in parallel by other TPUs. In this experiment, an iteration consists of generating 256 games through self-play, then doing one epoch of training, split into 3904 mini-batches of size 256, after 7 iterations once the frame window is full. In terms of positions seen, one iteration is equivalent to 244 steps.

5.1 实施

Jax和PGX。由于MCTS算法在树探索过程中需要大量模型调用，因此必须拥有优化的GPU代码，同时运行模型调用和MCTS搜索。为了利用MCTX [8]中Gumbel MuZero的实现，我们所有的模型和实验都在Jax [3]及其生态系统 [11] [9]中实现。PGX [13]用于象棋实现，我们的AlphaZero实现基于PGX的AZNet实现。我们使用Aim [1]记录所有实验。

为了估计Elo评分，我们使用了statsmodels包[16]中实现的加权最小二乘法（WLS）。

硬件。所有模型都是使用多个Nvidia RTX A5000 GPU训练的（*Learning speed*使用了8个，*Fine-tuning*使用了6个），他们的Elo等级是使用其中6个GPU估算的。

5.2 评估

由于每次训练和评估持续时间约为一周，我们目前还没有机会对每种模型配置进行多次训练。因此，我们在结果中呈现的每种模型只训练了一次，我们包括的置信区间是基于我们为它们估计的Elo评分，如以下所述。

在训练过程中，每隔一定次数（每2次、5次或10次迭代），模型参数会被保存，并使用这一组参数来评估Elo等级。在本节中，我们将一对（模型，参数）称为一个玩家，并为每个玩家计算一个等级。

我们最初选择了10名选手，并模拟了每对选手之间进行60场比赛，以获取初始比赛数据 M 。对于每一对进行了比赛的选手，我们存储了胜场数 w_{ij} 、平局数 d_{ij} 和负场数 l_{ij} ： $M_{ij} = (w_{ij}, d_{ij}, l_{ij})$ 。利用这些数据，我们可以使用以下方程组进行线性回归，粗略估计 M 中在场选手的等级 $r \in \mathbb{R}^{N_{players}}$ ：

$$\begin{cases} r_j - r_i = \frac{400}{\log(10)} \log \left(\frac{w_{ij} + d_{ij} + l_{ij} + 1}{w_{ij} + \frac{d_{ij}+1}{2}} - 1 \right) & \text{for } i \in M, j \in M_i, \\ \sum_{i \in M} r_i = |M| \times 1000. \end{cases} \quad (11)$$

我们人为地添加一局平局，以避免只有一方只有胜利而没有失败的极端情况，在这种情况下，评级差异理论上会无限大。这相当于一个Jeffreys先验。最后一个方程将平均评级固定为1000，因为Elo评级整体上通过平移是不变的。

我们随后运行了算法 2 生成一个密集连接的比赛数据图，其中每个玩家至少与 5 名实力相近的其他玩家进行了比赛。最后，我们使用该数据集拟合了一个加权最小二乘回归模型来获得我们在实验结果图中使用的 Elo 排名。置信区间通过假设归一化后的比赛结果遵循正态分布来估计。如果 $\hat{p}_{ij} = \frac{w_{ij} + \frac{d_{ij}+1}{2}}{w_{ij} + d_{ij} + l_{ij} + 1}$ 是玩家 i 击败玩家 j 的估计概率，我们近似认为 p_{ij} 遵循的分布为正态分布，并使用 delta 方法推导出 $r_j - r_i$ 渐近地遵循均值为 $\frac{400}{\log(10)} \log \left(\frac{1}{\hat{p}_{ij}} - 1 \right)$ 、方差为 $\left(\frac{400}{\log(10)} \right)^2 \frac{1}{(\hat{p}_{ij} + d_{ij} + l_{ij})\hat{p}_{ij}(1-\hat{p}_{ij})}$ 的正态分布。证明详见附录 A.2。使用 statsmodels [16] 的加权最小二乘线性模型，我们为每个玩家获得了 Elo 排名及其标准差，我们使用这些标准差在后续中推导出 2 倍标准差的置信区间。

5.3 实验

学习速度。我们的第一个实验比较了AlphaGateau基线能力从零开始学习如何玩8×8国际象棋，并将其与一个缩小版的AlphaZero模型进行了比较。AlphaZero模型包含5个残差层（包含10个CNN层）和总共220万参数，而AlphaGateau模型也有5个ResGATEAU层（包含10个GATEAU层）和总共100万参数，因为它在策略头中不需要一个完全连接层，而GATEAU层使用的是3×3 CNN参数的2/3。

```

Parameters:  $N_{games} = 60, N_{sim} = 128$ 
Input:  $M$ 
for player in unmatched players do
    for  $i \leftarrow 1$  to 5 do
         $r \leftarrow \text{Elo\_LR}(M)$ ; /* The Linear Regression is run on Eq. 11 */
        opponent  $\leftarrow \text{argmin}_{j \in M} |r_j - r_{\text{player}}|$ ; /* If player  $\notin M$ , we set  $r_{\text{player}} = 1000$  */
         $(w, d, l) \leftarrow \text{play}(\text{player}, \text{opponent}, N_{games}, N_{sim})$ ;
         $M_{\text{player}, \text{opponent}} \leftarrow M_{\text{player}, \text{opponent}} + (w, d, l)$ ;
         $M_{\text{opponent}, \text{player}} \leftarrow M_{\text{opponent}, \text{player}} + (l, d, w)$ ;
    end
end

```

我们在图5中报告了估算的Elo评分及其2sigma置信区间。AlphaZero在500次迭代中仅能达到 667 ± 38 的Elo评分，并且在获得更多时间的情况下很可能会继续改进，而AlphaGateau达到了 2105 ± 42 的Elo评分，在最初的50次迭代中表现出爆炸性的增长，并且在仅10次迭代后就达到了与AlphaZero最终Elo评分相媲美的结果。

Fine-tuning. 在我们的第二次实验中，我们训练了一个带有10个残差层的AlphaGateau模型，在5×5国际象棋上训练了100个迭代，然后在这个模型上使用8×8国际象棋进行了100个迭代的微调。该模型总共有1.7M个参数。

我们在图6中报告了带有2sigma置信区间的估计Elo评分。初始训练在评估了8×8国际象棋游戏后结束，Elo评分为 807 ± 46 ，这表明它能够在5×5国际象棋中学习到一般的棋规，并在没有见过任何8×8国际象棋局面的情况下，成功地应用到8×8国际象棋中。一旦开始微调，模型在几次迭代后跳到了 1181 ± 50 的Elo评分，这表明在5×5国际象棋上学习到的基线质量很高。经过微调后，模型的Elo评分为 1876 ± 47 ，尽管其大小是较小模型的两倍，但在大致相同的迭代次数和GPU时间下达到了相当的性能。初步测试表明，如果每次迭代生成更多的数据，该模型会变得更强大，但这也意味着训练时间将线性增加，因为生成自我对弈游戏占用了五天训练时间的一半。

为了训练更深的网络，我们实验了每一代生成的自我对弈游戏的数量，以及帧窗口的大小。从图7的结果来看，有更多的新生成数据似乎有助于模型更快地学习。然而，每个迭代所需的时间与生成的游戏数量成线性关系，模型仍然能够使用较旧的数据进行改进。因此，保留一部分之前迭代的帧窗口是一个不错的折中方案。然而，我们还有改进帧窗口选择的方法：




图 5: AlphaZero 和 AlphaGateau (带有 5 个残差层) 在 500 次迭代中训练的 Elo 评级。AlphaGateau 模型最初比 AlphaZero 模型快 10 倍的学习, 经过 100 次迭代后, 其增长速度与 AlphaZero 相当。




图 6: 将 AlphaGateau 模型 (如图 5 所示) 前 100 次迭代的 Elo 评级包括在内, 用于比较。初始在 5×5 围棋上的训练能够提高其评级, 即使在训练过程中评估的是 8×8 围棋, 也没有见过任何 8×8 围棋的局面。微调后的模型从一个良好的基线开始, 并达到了与 5 层模型相当的性能。尽管规模较大, 但训练不足。

- 哪些先前的样本应该被选择? 我们从之前的帧窗口中随机选择样本来补充新生成的样本, 但选择更少的样本可能更好, 这些样本能够代表不同的位置范围。
- 过去的的数据设计上质量可疑。因为它们来自使用之前模型参数的自我对弈游戏, 所以这些数据对应的是使用较低棋力水平进行的游戏, 而MCTS输出的策略也较差。保留太旧的数据样本可能会导致性能下降而不是帮助模型学习。我们尝试过保留最近的100万样本, 但效果不佳。

我们最初也尝试在一次迭代中增加迭代次数, 但只看到了边际收益, 这表明在先前帧窗口中混合新数据有助于模型从先前样本中提取更多的训练信息。




Figure 7: 两个模型使用大小为131 072的帧窗口, 只保留了帧窗口中最新生成的游戏。不使用帧窗口并生成256个游戏的模型仅用了39小时进行训练, 但性能最差。添加1M大小的帧窗口稍微改善了性能, 耗时60小时, 而将自对弈游戏的数量增加到1024个性能最佳, 但需要198小时。

6 结论

在本文中，我们介绍了AlphaGateau，这是一种AlphaZero模型设计的变体，将国际象棋游戏状态表示为图，以提高性能并使其能够更好地泛化到游戏的变体中。从基于网格的CNN到基于图的GNN的这一变化带来了性能的显著提升，并似乎有望促进基于强化学习的游戏玩牌代理研究，因为它减少了训练所需资源。

我们还介绍了一种GAT的变体GATEAU，我们设计它以简单的方式处理边特征，并且表现良好且效率高。

Future Work. 由于我们的模型在与初始AlphaZero相比时相对较浅，因此需要确认当两者都使用完整的40层架构进行训练时，AlphaGateau仍然优于AlphaZero。这将需要更多的计算时间和资源。

如第5.4节所述，我们设计的帧窗口略显不足，未来的一个改进是定义一个高效可计算的棋局相似度量，这有助于神经网络泛化。

我们在这篇论文中专注于国际象棋，但其他游戏也可以从这种新方法中受益。第一个就是将棋，因为它有类似国际象棋的规则，AlphaGateau的有希望的一般化结果可以用于在一种游戏中训练模型，然后在另一种游戏中微调它，或者同时在这两种游戏中训练它，以拥有一个更通用的游戏代理。如图设计 4.2 所暗示的，为了使国际象棋图和将棋图的节点和边特征兼容，需要更多的特征工程。也有可能改变模型架构以处理具有更具挑战性特性的游戏，例如有超过两名玩家、随机性、隐藏信息和变化地图的Risk游戏，但将棋更适合作为图来表示。

Acknowledgments 和 资金披露

这项工作得到了JST BOOST的支持，资助编号JPMJBS2407，以及JST CREST的支持，资助编号JPMJCR21D1。我们感谢Armand Barbot和Jill-Jënn Vie提供的宝贵意见和深入讨论。

参考文献

- [1] G. Arakelyan, G. Soghomonyan, 和 The Aim 团队. Aim, 2020年6月. URL <<https://github.com/aimhubio/aim>>.
- [2] S. Ben-Assayag 和 R. El-Yaniv. 小规模训练，大规模游戏：使用 AlphaZero 和 GNN 扩大规模棋盘游戏，2021年7月。URL <http://arxiv.org/abs/2107.08387>. arXiv:2107.08387 [cs].
- [3] J. Bradbury, R. Frostig, P. Hawkins, M. J. Johnson, C. Leary, D. Maclaurin, G. Necula, A. Paszke, J. VanderPlas, S. Wanderman-Milne, 和 Q. Zhang. JAX: 2018 年可组合变换的 Python+NumPy 程序, URL <http://github.com/google/jax>.
- [4] 陈健和陈华. 边特征图注意网络，2021年1月. URL <http://arxiv.org/abs/2101.07671>. arXiv:2101.07671 [cs].
- [5] R. Coulom. 整个历史评级：时间变化强度玩家的贝叶斯评级系统. 在 D. Hutchison, T. Kanade, J. Kittler, J. M. Kleinberg, F. Mattern, J. C. Mitchell, M. Naor, O. Nierstrasz, C. Pandu Rangan, B. Steffen, M. Sudan, D. Terzopoulos, D. Tygar, M. Y. Vardi, G. Weikum, H. J. Van Den Herik, X. Xu, Z. Ma, 和 M. H. M. Winands 编辑, *Computers and Games*, 第 5131 卷, 第 113–124 页. Springer Berlin Heidelberg, 柏林, 德国, 2008 年. ISBN 978-3-540-87607-6 978-3-540-87608-3. doi: 10.1007/978-3-540-87608-3_11. URL https://link.springer.com/10.1007/978-3-540-87608-3_11. 系列标题：计算机科学讲义。
- [6] J. 捷克, P. 科鲁斯, 和 K. 基尔斯坦. AlphaZero 的 Monte-Carlo 图搜索, 2020年12月. URL <https://arxiv.org/abs/2012.11045v1>.

- [7] I. Danihelka, A. Guez, J. Schrittwieser, 和 D. Silver. 使用Gumbel进行规划以改进策略。2021年10月。URL <https://openreview.net/forum?id=bERaNdoegnO>.
- [8] DeepMind, I. Babuschkin, K. Baumli, A. Bell, S. Bhupatiraju, J. Bruce, P. Buchlovsky, D. Budden, T. Cai, A. Clark, I. Danihelka, A. Dedieu, C. Fantacci, J. Godwin, C. Jones, R. Hemsley, T. Hennigan, M. Hessel, S. Hou, S. Kapturowski, T. Keck, I. Kemaev, M. King, M. Kunesch, L. Martens, H. Merzic, V. Mikulik, T. Norman, G. Papamakarios, J. Quan, R. Ring, F. Ruiz, A. Sanchez, L. Sartran, R. Schneider, E. Sezener, S. Spencer, S. Srinivasan, M. Stanojević, W. Stokowiec, L. Wang, G. Zhou, 和 F. Viola. DeepMind JAX 生态系统, 2020. URL <http://github.com/deepmind>.
- [9] J. Godwin*, T. Keck*, P. Battaglia, V. Bapst, T. Kipf, Y. Li, K. Stachenfeld, P. Veličković, 和 A. Sanchez-Gonzalez. Jraph: 一个在 Jax 中的图神经网络库, 2020. URL <http://github.com/deepmind/jraph>.
- [10] Gong L. 和 Cheng Q. 利用图神经网络中的边特征, 2019年1月。URL <http://arxiv.org/abs/1809.02709>. arXiv:1809.02709 [cs, stat].
- [11] J. Heek, A. Levskaya, A. Oliver, M. Ritter, B. Rondepierre, A. Steiner, 和 M. v. Zee. Flax: 一个针对 JAX 的神经网络库及其生态系统, 2023. URL <http://github.com/google/flax>.
- [12] D. P. Kingma 和 J. Ba. Adam: 一种随机优化方法, 2017年1月。URL <http://arxiv.org/abs/1412.6980>. arXiv:1412.6980 [cs].
- [13] S. 科山达, S. 岡ano, S. 西森ori, Y. 森田, K. 北原, H. 北田, 和 S. 是枝. Pgx: 为强化学习加速的并行游戏模拟器硬件, 2024年1月。URL <http://arxiv.org/abs/2303.17503>. arXiv:2303.17503 [cs].
- [14] 李洋, 大卫·塔罗, 马库斯·布罗克肖姆, 和 里克·泽梅尔. 门控图序列神经网络, 2017年9月。URL <http://arxiv.org/abs/1511.05493>. arXiv:1511.05493 [cs, stat].
- [15] J. Schrittwieser, I. Antonoglou, T. Hubert, K. Simonyan, L. Sifre, S. Schmitt, A. Guez, E. Lockhart, D. Hassabis, T. Graepel, T. Lillicrap, and D. Silver. 通过规划使用学习模型掌握雅达利、围棋、国际象棋和将棋. *Nature*, 588(7839):604–609, 2020年12月。ISSN 0028-0836, 1476-4687。doi: 10.1038/s41586-020-03051-4。URL <http://arxiv.org/abs/1911.08265>. arXiv:1911.08265 [cs, stat].
- [16] S. Seabold 和 J. Perktold. statsmodels: 使用 Python 进行计量经济和统计建模. 在 *9th Python in Science Conference*, 2010.
- [17] D. Silver, A. Huang, C. Maddison, A. Guez, L. Sifre, G. Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot, S. Dieleman, D. Grewe, J. Nham, N. Kalchbrenner, I. Sutskever, T. Lillicrap, M. Leach, K. Kavukcuoglu, T. Graepel, and D. Hassabis. 使用深度神经网络和树搜索掌握围棋游戏. *Nature*, 529:484–489, 2016年1月。doi: 10.1038/nature16961。
- [18] D. Silver, T. Hubert, J. Schrittwieser, I. Antonoglou, M. Lai, A. Guez, M. Lanctot, L. Sifre, D. Kumaran, T. Graepel, T. Lillicrap, K. Simonyan, 和 D. Hassabis. 通过自我对弈掌握国际象棋和将棋: 一种通用强化学习算法, 2017年12月。URL <https://arxiv.org/abs/1712.01815v1>。
- [19] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, 和 Y. Bengio. 图注意力网络, 2017年10月。URL <https://arxiv.org/abs/1710.10903v3>。
- [20] K. Xu, W. Hu, J. Leskovec, 和 S. Jegelka. 图神经网络有多强大? , 2018年10月。URL <https://arxiv.org/abs/1810.00826v3>。

附录 / 补充材料

A.1 棋手 Elo

Elo排名系统最初被引入作为一种评估国际象棋玩家棋力的方法。每位玩家的排名应该是动态的，并在他们每场比赛后进行调整以反映他们的进步。

The Elo排名定义为满足以下性质：如果两名玩家的Elo排名分别为 R_A 和 R_B 进行了比赛，那么玩家A获胜的概率为

$$E_A = \frac{1}{1 + 10^{\frac{R_B - R_A}{400}}}. \quad (12)$$

A.2 估计Elo等级差的方差

我们假设两名Elo等级为 R_A 和 R_B 的玩家之间的比赛结果是一个伯努利试验，玩家A获胜的概率由中心Elo方程12给出。如果我们想估计两名玩家的Elo等级，我们需要估计这个概率 p 。为此，我们可以让两名玩家进行 n 场比赛，并将玩家A的胜利次数与其一半的平局次数相加，得到 $x = w + \frac{d}{2}$ 。从这个结果，我们可以使用估计器 $\hat{p} = \frac{x}{n}$ 来估计 p 的值。如果其中一名玩家明显比另一名玩家强得多， \hat{p} 可能接近0或1，在这种情况下，这个估计器会非常不准确。为了解决这个问题，我们将依赖Jeffreys先验来得到估计器 $\hat{p}_{Jeffreys} = \frac{x+1/2}{n+1}$ 。我们将在以下部分将这个估计器记作 \hat{p} 。

从我们的假设出发，我们有 x 遵循二项分布 $B(n, p)$ ，并且我们将用正态分布 $\hat{p} \sim \mathcal{N}(p, \frac{p(1-p)}{n})$ 近似 \hat{p} 的分布。

通过反转Elo方程12，我们可以从A获胜的概率得到评级差为

$$R_B - R_A = \frac{400}{\log(10)} \log\left(\frac{1}{p} - 1\right), \quad (13)$$

因此，提出 $g(y) = \frac{400}{\log(10)} \log\left(\frac{1}{y} - 1\right)$ ，这是一个可微函数，我们可以使用delta方法得到 $g(\hat{p})$ 是渐近正态的。 g 的导数为

$$\begin{aligned} g'(y) &= \frac{400}{\log(10)} \left(-\frac{1}{y^2}\right) \left(\frac{1}{\frac{1}{y} - 1}\right) \\ &= -\frac{400}{\log(10)} \frac{1}{y^2} \frac{y}{y-1} \\ &= -\frac{400}{\log(10)} \frac{1}{y(y-1)}, \end{aligned} \quad (14)$$

which gives

$$\begin{aligned} \hat{R}_B - \hat{R}_A = g(\hat{p}) &\sim \mathcal{N}\left(g(p), \frac{p(1-p)}{n} (g'(p))^2\right) \\ &\sim \mathcal{N}\left(\frac{400}{\log(10)} \log\left(\frac{1}{p} - 1\right), \frac{p(1-p)}{n} \left(-\frac{400}{\log(10)} \frac{1}{p(p-1)}\right)^2\right) \\ &\sim \mathcal{N}\left(\frac{400}{\log(10)} \log\left(\frac{1}{p} - 1\right), \frac{400^2}{\log(10)^2} \frac{p(1-p)}{n} \frac{1}{(p(p-1))^2}\right) \\ &\sim \mathcal{N}\left(\frac{400}{\log(10)} \log\left(\frac{1}{p} - 1\right), \frac{400^2}{\log(10)^2} \frac{1}{np(p-1)}\right). \end{aligned} \quad (15)$$

A.3 与 BayesElo 的比较

我们还使用了 BayesElo[5] 来使用记录的所有模型之间对弈生成的 PGN 文件评估我们模型的 Elo 评分。在图 8 中，我们绘制了一个点

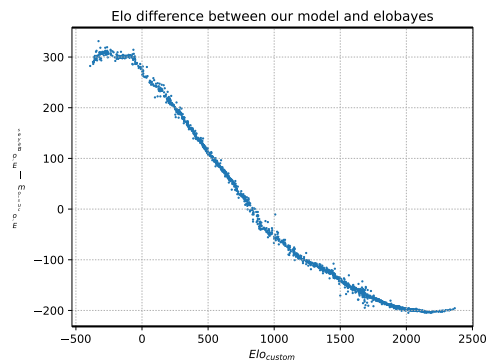


图 8: 根据我们方法计算的 BayesElo 评级与 Elo 评级之间的差异。我们从每个 Elo 中减去了其相应方法中所有玩家的平均 Elo, 使得 BayesElo 和我们方法的平均有效 Elo 值均为 0




Figure 9: 与图5比较的副本。




图 10: 将图 5 中的迭代次数改为使用运行时间几乎没有变化, 因为 AlphaZero 只比 AlphaGateau 稍微快一点。

在每个玩家的 (x, y) 上, 其中 x 是其按照我们方法计算的 Elo 评分, 而 y 是我们方法与 Bayes Elo 预测 Elo 差异。

在实践中, 我们的方法倾向于将较弱的模型高估, 相对于 Bayes Elo 而言, 而较强的模型则被低估。由于这种关系是平滑且单调的, 这表明两种方法以相似的方式对所有玩家的相对实力进行排序, 只有细微的差异可能是由于噪声造成的。主要的区别在于我们的 Elo 评分范围向极端压缩, 我们假设这是由于我们实用的 Jeffreys 先验导致的, 这种先验表明较强的模型至少与所有对手进行过一场比赛, 从而限制了它们的 Elo 评分; 类似地, 较弱的模型总是能够至少避免输给某个对手。

A.4 FLOPs 比较

我们没有记录模型的 FLOPs, 但是我们记录了每个迭代所需的时间。在图 10、12 和 14 中, 我们使用这些数据在 X 轴上绘制了主要论文的三个主要图表。由于有些实验使用了 6 块 GPU 而不是 *, 我们将它们记录的时间乘以一个因子 $\frac{6}{8}$ 以进行更好的比较。

A.5 PGNs

我们随附了图 15、16 和 17 中显示的由我们的模型对弈的部分 PGN 棋局。




Figure 11: 与图6比较的副本。




图 12: 使用运行时间而不是迭代次数来表示图 5。训练深度模型大约需要多出 40 小时，生成的游戏数量和训练步骤相似。




Figure 13: 与图7比较的副本。




图 14: 将运行时间而不是迭代用于图 5 显示，尽管使用更多新生成的游戏而不是依赖于之前数据的帧窗口可以使模型每迭代改进更多，但实际上这会导致训练速度变慢。

图 15 包含了在 8×8 棋盘上由我们精细调优实验的最后一轮迭代的 5×5 AlphaGateau 模型下的一局游戏的 PGN，以展示其游戏风格，同时在其训练过程中从未见过 8×8 的棋盘。

图16和图17包含我们在第一次实验中完整AlphaGateau模型的最后一轮（第499轮）作为白方和黑方所下棋局的PGN，这些棋局是从与其他模型对弈的棋局中挑选出来的，用于评估所有Elo排名，使用GitHub仓库中的book.py脚本选择，并按照每步棋最常走的棋路。图16中作为白方的棋局是对抗一个使用8层、每轮生成1024场游戏但仅进行32次MCTS模拟的细调AlphaGateau模型的第61轮。图17中作为黑方的棋局是对抗同一模型的第439轮。

A.6 谁仕士评价

我们对5层AlphaGateau模型进行了最终迭代的运行，在Lichess上使用了名为AlphaGateau的机器人 (<https://lichess.org/@/AlphaGateau>)。我们通过改变MCTS模拟次数来调整每步棋所需的时间，让机器人与其他机器人和一些人类玩家在标准、blitz和快速对局格式中进行对弈。这通过使用默认的Lichess机器人桥接程序 (<https://github.com/lichess-bot-devs/lichess-bot>) 实现，相关的代码位于我们GitHub仓库的lichess文件夹中。

在2024年10月底，经过每次进行100到200场比赛后，AlphaGateau 达到了超快棋 Elo 1991、快棋 Elo 1829 和 慢棋 Elo 1884。

1. e4 c6 2. h3 h6 3. Be2 Na6 4. g4 g6 5. a4 Rh7 6. f4 f6 7. Nf3 Bg7 8. h4 d5 9. e5 Nb4 10. c3 Bxg4 11. cxb4 Bh5 12. Ng1 Bh8 13. Nc3 d4 14. Rh3 a5 15. exf6 Nxf6 16. bxa5 e6 17. Bxh5 gxh5 18. b4 Ng8 19. Rd3 Nf6 20. Nge2 Ng4 21. Qc2 Qxh4+ 22. Ng3 Qh2 23. Nge4 Qh1+ 24. Ke2 Rg7 25. Rx d4 Qh2+ 26. Kf3 Qh1+ 27. Ke2 Rf7 28. Rd3 Qg2+ 29. Ke1 Rg7 30. Ra2 Qh1+ 31. Ke2 Ke7 32. Rg3 Re8 33. Qd3 Rd8 34. Qc4 Qh4 35. Ra1 Rf7 36. Ra2 Rxf4 37. d4 Rf7 38. Be3 Rg7 39. Rc2 Kf7 40. Qc5 Ke8 41. Rf3 Qh2+ 42. Kd3 Qh1 43. Rf4 Nxe3 44. Kxe3 Rg1 45. Re2 Rxd4 46. Nf2 Rxf4 47. Nxh1 Rh4 48. Nf2 Kd7 49. b5 Rg3+ 50. Kd2 Bxc3+ 51. Kc2 Bh8 52. Qb6 Kd6 53. a6 bxa6 54 . Qd8+ Kc5 55. Qxh4 Rg8 56. bxc6 Kxc6 57. Qf4 Bg7 58. Rxe6+ Kd5 59. Qf5+ Kc4 60. Qf3 Kb4 61. Qxh5 Kxa4 62. Rxa6+ Kb4 63. Qf5 Rh8 64. Ra7 Bd4 65. Rb7+ Bb6 66. Nd3+ Ka4 67. Re7 h5 68. Qf6 Bd8 69. Qf4+ Kb5 70. Re5+ Kb6 71. Nf2 Kc7 72. Ne4 Kc6 73. Kc3 Kb6 74. Kd4 Kc6 75. Ng3 Kb6 76. Kc4 Kb7 77. Qf3+ Kc7 78. Kd5 h4 79. Ne2 h3 80. Qf4 Kd7 81. Ng3 Kc7 82. Rh5+ Kd7 83. Rxh8 h2 84. Rxh2 Bc7 85. Qf2 Kc8 86. Qf5+ Kb7 87. Qd7 Ka8 88. Ke4 Bb8 89. Rh6 Ba7 90. Rf6 Bg1 91. Rf5 Kb8 92. Rf8#

图15: 仅使用5×5国际象棋（作为白方）完全训练的模型下的一局棋。白方能够使用他们的白象来消除黑方的白象，但在第14步似乎低估了他们的马，可能是因为在5×5国际象棋中马的性能较差，由于活动范围受限且更难有效运用

1. e4 c5 2. Nb1c3 e6 3. Ng1f3 Nb8c6 4. d4 d4 5. Nf3d4 Ng8f6 6. Nd4c6 c6 7. e5 Nf6d5 8. Nc3e4 Qd8c7 9. f4 Qc7b6 10. Bf1e2 Bc8a6 11. Be2a6 Qb6a6 12. a3 h5 13. Qd1e2 Qa6e2 14. Ke1e2 f5 15 . Ne4c3 a5 16. Nc3d5 d5 17. Bc1e3 Bf8e7 18. c3 Rh8g8 19. Ke2f3 g5 20. g3 g4 21. Kf3e2 h4 22. b 4 Ke8f7 23. Ra1c1 h3 24. Be3b6 b4 25. b4 Ra8a3 26. Rc1c7 Rg8b8 27. Bb6c5 Be7c5 28. Rc7c5 R b8b4 29. Rc5c2 d4 30. Rh1d1 Kf7e7 31. Ke2f2 Ra3f3 32. Kf2g1 d3 33. Rc2c3 Rb4b2 34. Rc3d3 R f3d3 35. Rd1d3 Rb2c2 36. Rd3d1 Rc2g2 37. Kg1h1 Rg2a2 38. Kh1g1 Ke7e8 39. Rd1b1 Ra2g2 40. Kg1h1 Rg2c2 41. Kh1g1 Rc2c3 42. Rb1b8 Ke8e7 43. Rb8b1 Rc3c2 44. Rb1b7 Rc2c1 45. Kg1f2 R c1h1 46. Kf2e2 Rh1h2 47. Ke2f1 Rh2g2 48. Rb7b3 Rg2d2 49. Kf1g1 Ke7f7 50. Rb3b7 Kf7f8 51. Rb7b8 Kf8f7 52. Kg1h1 Rd2g2 53. Rb8b7 Kf7e7 54. Rb7d7 Ke7e8 55. Rd7d3 Rg2f2 56. Rd3d6 K e8e7 57. Rd6c6 Rf2f3 58. Rc6c7 Ke7d8 59. Rc7c6 Kd8d7 60. Rc6d6 Kd7e7 61. Kh1h2 Rf3f2 62. Kh2h1 Rf2f3 63. Kh1h2 Rf3f2 64. Kh2h1 Rf2g2 65. Rd6d3 Rg2c2 66. Rd3d4 Rc2c3 67. Kh1h2 Rc 3a3 68. Rd4d2 Ra3a6 69. Rd2e2 Ra6a5 70. Re2d2 Ra5a1 71. Rd2b2 Ra1a8 72. Kh2h1 Ra8c8 73. K h1g1 Rc8a8 74. Rb2b6 Ke7d7 75. Rb6d6 Kd7e7 76. Kg1h1 Ra8a3 77. Kh1h2 Ra3a2 78. Kh2h1 Ra 2a7 79. Kh1g1 Ra7a1 80. Kg1h2 Ra1a2 81. Kh2h1 Ra2e2 82. Rd6d4 Re2g2 83. Rd4d3 Ke7e8 84. Rd3a3 Rg2e2 85. Ra3d3 Re2e1 86. Kh1h2 Re1e2 87. Kh2h1 Re2b2 88. Rd3c3 Rb2a2 89. Rc3c6 K e8d7 90. Rc6d6 Kd7e7 91. Rd6c6 Ra2e2 92. Rc6c3 Re2g2 93. Rc3d3

图16: AlphaGateau 从一个封闭的西西里开局，转为四骑士西西里，遵循一条流行路线直到第10回合，此时白方将其白象移至e2。在第35回合时，棋盘的兵形结构锁定了局势。在比赛结束成和棋之前，除了第54回合的一个有趣的僵局技巧外，没有什么事情发生。

1. e4 e5 2. Nf3 Nc6 3. Bb5 Nf6 4. d3 Bc5 5. Bxc6 dxc6 6. O-O Qe7 7. Bg5 O-O 8. Bh4 h6 9. Nbd2 b5 10. Qe1 a5 11. h3 Bb6 12. Bg3 Re8 13. Bxe5 a4 14. Bc3 Nh5 15. a3 Nf4 16. Kh2 f5 17. Qd1 Rf 8 18. exf5 Rxf5 19. Qe1 Qf7 20. g4 Rc5 21. Ne4 Rd5 22. Rg1 Ne6 23. Nh4 Ng5 24. Nf6+ gxf6 25. f4 Ne6 26. Rg3 Nd4 27. Qe4 Bd7 28. Re1 Re8 29. Qg2 Rxe1 30. Bxe1 Qe6 31. Bf2 Ne2 32. Bxb6 cxb6 33. f5 Qe5 34. Nf3 Qxg3+ 35. Qxg3 Nxg3 36. Kxg3 Bc8 37. Kf4 Rd7 38. Nd2 Kf7 39. Ne4 Ba6 40. h4 c5 41. g5 fxg5+ 42. hxg5 hxg5+ 43. Nxg5+ Kg7 44. Ke5 Re7+ 45. Ne6+ Kf7 46. Kd6 Bc8 47. Ng5+ Kf6 48. Ne4+ Kf7 49. Ng5+ Kf8 50. f6 Rd7+ 51. Kc6 c4 52. Ne6+ Kf7 53. Nf4 Kx f6 54. Nd5+ Ke6 55. Nxb6 cxd3 56. cxd3 Bb7+ 57. Kxb5 Rxd3 58. Nc3 Kd6 59. Kc4 Rh3 60. Nc3 Kc6 61. b4 Bc8 62. a4 Be6+ 63. Kd4 Bb3 64. a5 Rh4+ 65. Ke5 Rxb4 66. a6 Kb6 67. Nb1 Bc2 68. Nc3 Bb3 69. Ne2 Kc5 70. Nf4 Ra4 71. Nd3+ Kc6 72. Nf4 Bc4 73. Ng6 Bxa6 74. Nf4 Bc4 75. Ng2 Bb3 76. Nf4 Bc2 77. Ne6 Re4+ 78. Kf5 Re1+ 79. Kf6 Kd6 80. Nf4 Rg1 81. Ne2 Rf1+ 82. Kg5 Ke 5 83. Ng3 Rf7 84. Nh5 Bd3 85. Ng3 Rg7+ 86. Kh4 Rg8 87. Kh3 Kf4 88. Nh5+ Kg5 89. Ng3 Rh8 + 90. Kg2 Kf4 91. Nf1 Rb8 92. Ng3 Rb2+ 93. Kh3 Bg6 94. Nh5+ Bxh5 95. Kh4 Rh2#

图17: AlphaGateau开始走柏林防御，没有参考任何棋谱，并在第4步偏离常规路线进入一个流行开局，第7步的罕见bishop走法。中局围绕着黑方强大的骑士展开，直到白方被迫放弃剩余的车以阻止攻击，从而黑方多一车一兵的优势。

NeurIPS论文检查清单

1. 声称

问题：摘要和引言中提出的主旨是否准确反映了论文的贡献和范围？

Answer: [是的]

论证：实验结果和图5、6和7中所示的支持了摘要和引言中的论点。

指南：

- The answer NA意味着摘要和引言不包括论文中提出的主张。
- 摘要和/或引言应清楚地陈述所提出的主张，包括论文中的贡献、重要假设和限制。对这个问题的回答如果是“No”或“NA”，不会被评审人很好地接受。
- 声明应与理论和实验结果相符，并反映这些结果预期能在其他设置中泛化的能力。
- 它可以包含进取性的目标以作为激励，只要这些目标清楚地不是论文所达到的。

2. 限制

问题：论文是否讨论了作者所完成工作的局限性？

Answer: [是的]

正当性说明：我们的主要限制是计算资源有限，模型的深度为5或10，而40会更好，并且我们仅专注于国际象棋而没有涉及其他游戏。此外，由于可用时间限制，我们只能运行一次实验，因此置信区间仅适用于评级估计，而不是基于多次训练运行的估计。

指南：

- The answer NA意味着论文没有限制，而回答No意味着论文有未讨论的限制。
- 作者被鼓励在他们的论文中创建一个单独的“局限性”部分。
- 论文应指出任何强有力的假设，并说明这些假设被违反时结果的稳健性（例如，独立性假设、无噪声设置、模型良好指定、渐近近似仅局部成立）。作者应反思这些假设在实践中可能如何被违反及其影响。
- 作者应该反思所提出的主张的范围，例如，如果该方法仅在几个数据集或几次运行中进行了测试。一般来说，实证结果往往依赖于一些隐含的假设，这些假设应该被阐明。
- 作者应该反思影响该方法性能的因素。例如，当图像分辨率低或图像在低光环境下拍摄时，面部识别算法可能会表现不佳。或者，由于无法处理技术术语，语音转文本系统可能无法可靠地为在线讲座提供字幕。
- 作者应该讨论所提出的算法的计算效率及其随数据集大小的扩展情况。
- 如果适用，作者应讨论其方法的可能局限性，以解决隐私和公平性问题。
- 虽然作者可能会担心完全诚实地承认局限性可能会被审稿人用作拒绝论文的理由，但更糟糕的结果可能是审稿人发现论文中没有承认的局限性。作者应该运用他们的最佳判断，并认识到个体制裁有利于透明度的行为在培养维护社区 integrity 的规范方面发挥着重要作用。审稿人将被明确指示不要因承认局限性的诚实而对其进行惩罚。

3. 理论假设与证明

问题: 对于每个理论结果, 论文是否提供了完整的假设集和完整的 (正确) 证明?

Answer: [是的]

证明: 唯一的理论结果是估计的Elo评分的置信区间闭式推导, 详见附录。

指南:

- The answer NA意味着论文中不包括理论结果。
- 论文中的所有定理、公式和证明都应该编号并交叉引用。
- 所有假设应在任何定理的陈述中明确指出或引用。
- 证明可以出现在主要论文或补充材料中, 但如果证明出现在补充材料中, 作者被鼓励提供一个简短的证明草图以提供直观理解。
- 相反, 论文核心部分提供的任何非正式证明应由附录或补充材料中提供的正式证明加以补充。
- 证明依赖的定理和引理应适当引用。

4. 实验结果可重复性

问题: 论文是否充分披露了所有用于重现论文主要实验结果的信息, 以至影响了论文的主要主张和/或结论 (无论代码和数据是否提供)?

Answer: [是的]

Justification: 我们在论文中包含了所有实验超参数和方法论, 并在摘要中提到的Git Hub仓库中发布了所有使用的代码。然而, 由于并行化的GPU代码不是完全确定性的, 因此无法复制我们呈现的精确训练结果, 因此我们还将发布一些我们在git仓库中保存的重要模型参数检查点。

指南:

- The answer NA意味着论文中没有包含实验。
- 如果论文包含实验, 对这个问题给出“没有答案”将不会被评审人很好地接受: 无论是否提供代码和数据, 使论文可重复是非常重要的。
- 如果贡献是一个数据集和/或模型, 作者应该描述他们采取的步骤以使其结果可重现或可验证。
- 根据贡献的不同, 可重现实验可以采用多种方式实现。例如, 如果贡献是一种新颖的架构, 那么完整描述该架构可能就足够了; 如果贡献是一种特定的模型和经验性评估, 那么可能需要使其他人能够使用相同的数据集复现该模型, 或者提供模型的访问途径。一般来说, 发布代码和数据通常是实现这一目标的一个好方法, 但可重现实验也可以通过提供详细的复现结果的步骤说明、访问托管模型 (例如, 在大型语言模型的情况下)、发布模型检查点或其他适用于所进行研究的方法来实现。
- 虽然 NeurIPS 不要求发布代码, 但该会议要求所有提交内容提供某种合理的可再现途径, 这可能取决于贡献的性质。例如: (a) 如果贡献主要是一种新算法, 论文应清楚说明如何再现该算法。(b) 如果贡献主要是一种新的模型架构, 论文应清楚完整地描述该架构。(c) 如果贡献是一种新模型 (例如, 一个大型语言模型), 则应有一种方法可以访问该模型以再现结果, 或者有一种方法可以再现该模型 (例如, 使用开源数据集或如何构建数据集的说明)。

(d) 我们认识到在某些情况下可重复性可能会有些棘手，在这种情况下，作者可以描述他们提供可重复性的具体方式。对于封闭源代码的模型，可能访问模型的方式会受到某种限制（例如，仅限注册用户），但其他研究人员应该能够找到某种途径来重现或验证结果。

5. 数据和代码的开放访问

问题: 论文是否提供了开放访问的数据和代码，并提供了足够的说明以忠实重现主要实验结果（如补充材料中所述）？

Answer: [是的]

Justification: 完整代码发布在 GitHub 仓库 Akulen/AlphaGateau。

指南:

- The answer NA意味着论文不包括需要代码的实验。
- 请参阅 NeurIPS 代码和数据提交指南 (<https://nips.cc/public/guides/CodeSubmissionPolicy>) 以获取更多详细信息。
- 虽然我们鼓励发布代码和数据，但我们理解这可能并不总是可行的，因此“不行”是一个可接受的答案。论文不能仅仅因为没有包含代码而被拒绝，除非这对于贡献至关重要（例如，对于一个新的开源基准）。
- 指令应包含用于重现结果所需的精确命令和环境。更多细节请参见 NeurIPS 代码和数据提交指南 (<https://nips.cc/public/guides/CodeSubmissionPolicy>)。
- 作者应提供数据访问和准备的说明，包括如何访问原始数据、预处理数据、中间数据和生成数据等。
- 作者应该提供脚本来重现新提出的方法和基线的所有实验结果。如果只有部分实验可以重现，他们应该说明哪些实验被脚本省略以及原因。
- 提交时，为了保护匿名性，作者应发布匿名版本（如果适用）。
- 提供尽可能多的补充材料（附在论文后面）中的信息是推荐的，但包含数据和代码的URL也是允许的。

6. 实验设置/细节

问题: 研究论文是否详细指明了所有用于理解结果的训练和测试细节（例如，数据分割、超参数、选择方式、优化器类型等）？

Answer: [是的]

正当性说明: 完整的训练流程已在论文中描述，提供的代码中包含了实施细节，例如gpu数据分割过程。

指南:

- The answer NA意味着论文中没有包含实验。
- 实验设置应在论文的核心部分以足够的细节呈现，以便读者能够理解并解读结果。
- 完整的细节可以与代码一起提供，在附录中，或作为补充材料。

7. 实验统计显著性

问题: 文章是否适当地并正确地报告了误差棒或其他关于实验统计显著性的适当信息？

Answer: [是的]

证明: 我们提供了我们估计的Elo等级的置信区间，然而，由于每个模型只训练了一次，这些是不完整的置信区间。

指南:

- The answer NA意味着论文中没有包含实验。
- 作者应该在结果伴有误差棒、置信区间或统计显著性检验（至少是支持论文主要论点的实验）时回答“是”。
- 误差棒捕获的可变性因素应明确说明（例如，训练/测试分割、初始化、某些参数的随机抽取，或给定实验条件下的整体运行）。
- 计算误差棒的方法应该解释清楚（闭形式公式、调用库函数、-bootstrap等）
- 所做的假设应该被给出（例如，正态分布的误差）。
- 应该清楚误差条是标准偏差还是标准误。
- 可以报告1- σ 误差棒，但应加以说明。如果误差的正态性假设未被验证，作者最好报告2- σ 误差棒，而不是声明其置信区间为96%。
- 对于非对称分布，作者在表格或图表中不应显示对称误差棒，以免得出超出范围的结果（例如负误差率）。
- 如果在表格或图表中报告了误差条，则作者应在文本中解释这些误差条是如何计算的，并引用相应的图表或表格。

8. 实验计算资源

问题: 对于每项实验，论文是否提供了足够的信息（包括计算工作者的类型、内存、执行时间）以重现这些实验？

Answer: [是的]

Justification: 我们包括GPU的数量和类型，以及实验运行时间。

指南:

- The answer NA意味着论文中没有包含实验。
- 论文应表明计算工作者的类型，是CPU或GPU，内部集群，还是云提供商，并包括相关的内存和存储信息。
- 论文应该提供每项单独实验所需的计算量，并估计总计算量。
- 论文应披露整个研究项目所需的计算资源是否超过了论文中报告的实验（例如，未纳入论文的初步或失败的实验）所需的计算资源。

9. 廉洁守则

问题: 研究论文中的研究在每一个方面都符合 NeurIPS 伦理守则 <https://neurips.cc/public/EthicsGuidelines>？

Answer: [是的]

证明: Justification: 证明确实是“证明”的意思，但源文本中“Justification”一词在不同上下文中可能有不同

指南:

- The answer NA意味着作者尚未审核NeurIPS伦理代码。
- 如果作者回答否，他们应该解释需要偏离伦理守则的特殊情况。
- 作者应该确保保护匿名性（例如，如果由于其管辖区域的法律或规定有特殊考虑）。

10. 更广泛的影响力

问题: 文章是否讨论了该工作可能产生的正面社会影响和负面社会影响？

Answer: [NA]

正当性：我们对现有的DRL架构进行改进，以训练游戏代理。目前这一改进没有直接的社会影响，因为其结果仅限于使该主题的研究更加 accessible，得益于训练效率的提升。

指南：

- The answer NA意味着该项工作没有社会影响。
- 如果作者回答NA或No，他们应该解释为什么他们的工作没有社会影响，或者为什么论文没有涉及社会影响。
- 负面社会影响的例子包括潜在的恶意或意外使用（例如，虚假信息、生成虚假资料、监控），公平性考虑（例如，部署可能不公平地影响特定群体的决策的技术），隐私考虑，以及安全考虑。
- 会议预计许多论文将是基础研究，并且不会特别针对特定的应用，更不用说部署了。然而，如果有直接途径导致任何负面应用，作者应该指出这一点。例如，指出生成模型的质量改进可能被用于生成用于虚假信息的deepfake是合理的。另一方面，并不需要指出一个用于优化神经网络的通用算法可以使人们更快地训练生成Deepfake的模型。
- 作者应该考虑该技术按预期使用且功能正常时可能产生的潜在危害，技术按预期使用但给出错误结果时可能产生的潜在危害，以及技术被故意或无意误用时可能产生的危害。
- 如果存在负面影响，作者也可以讨论可能的缓解策略（例如，模型的受控发布、提供防御而非仅仅攻击、监测滥用的机制、监测系统如何随时间反馈学习的机制、提高机器学习的效率和可访问性）。

11. 保障措施

问题：文章是否描述了为负责任地发布高风险易误用的数据或模型（例如，预训练语言模型、图像生成器或抓取的数据集）所采取的保护措施？

Answer: [NA]

证明：释放的模型远不如当前现有的国际象棋引擎强大，因为它们在计算原因上受到大小和深度的限制，因此发布它们是没有风险的。

指南：

- The answer NA意味着该论文不存在此类风险。
- 释放具有高风险误用或双重用途的模型时，应采取必要措施以控制模型的使用，例如要求用户遵守使用指南或限制访问模型，或实施安全过滤。
- 从互联网抓取的数据集可能会带来安全风险。作者应该描述他们是如何避免发布不安全图像的。
- 我们认识到提供有效的保护措施具有挑战性，而且许多论文不需要这样做，但我们鼓励作者将这一点考虑在内，并尽最大努力。

12. 现有资产的许可

问题：研究中使用的资产（例如，代码、数据、模型）的创建者或原始所有者是否得到了适当的认可，并且许可证和使用条款是否明确提及并得到了适当尊重？

Answer: [是的]

正当性说明：我们引用了开发和运行本文中呈现的实验所使用的每一个非标准Python库。除了这些库之外，我们没有使用任何先前的数据集或资产。

指南:

- The answer NA意味着论文未使用现有资产。
- 作者应该引用原始论文, 该论文产生了代码包或数据集。
- 作者应声明使用的是资产的哪个版本, 并在可能的情况下提供一个URL。
- 每个资产都应该包含许可名称(例如, CC-BY 4.0)。
- 对于从特定来源(例如网站)抓取的数据, 应该提供该来源的版权和服务条款。
- 如果释放了资产, 包中应提供许可证、版权信息和使用条款。对于流行的数据集, paperswithcode.com/datasets 已为一些数据集整理了许可证。他们的许可指南可以帮助确定数据集的许可证。
- 对于重新打包的现有数据集, 应提供原始许可和衍生资产的许可(如果已更改), {v*}
- 如果这些信息无法在线获得, 作者们被鼓励联系资产的创作者。

13. 新资产

问题: 文中引入的新资产是否得到了充分记录, 并且这些记录是否与资产一同提供?

Answer: [是的]

正当性说明: 随论文发布的 Git 仓库将包含结构良好的代码。

指南:

- The answer NA意味着论文不发布新资产。
- 研究人员应通过结构化的模板在其提交中传达数据集/代码/模型的详细信息。这包括训练细节、许可、限制等。
- 论文应该讨论是否以及如何获得使用他人资产时的同意。
- 在提交时, 请记住对您的资产进行匿名化(如果适用)。您可以创建一个匿名化链接或包含一个匿名化的压缩文件。

14. 众包与人类受试者研究

问题: 对于包含人类受试者的 crowdsourcing 实验和研究, 论文是否包含了提供给参与者的所有说明文本(如果适用), 以及屏幕截图, 还有关于补偿的详细信息(如果有)?

Answer: [NA]

证明: Justification: 证明确实是“证明”的意思, 但源文本中“Justification”一词在不同上下文中可能有不同指南:

- The answer NA意味着论文既不涉及众包也不涉及涉及人类受试者的研究。
- 包括这些信息在补充材料中是可以的, 但如果论文的主要贡献涉及人类受试者, 那么尽可能多的细节应该包含在主要论文中。
- 根据 NeurIPS 的伦理规范, 参与数据收集、整理或其他劳动的工人应至少获得数据收集国的最低工资。

15. 机构审查委员会 (IRB) 批准或等效批准用于人类受试者的研究

问题: 论文是否描述了研究参与者可能面临的潜在风险, 这些风险是否已向受试者披露, 以及是否获得了机构审查委员会 (IRB) 的批准(或等效的批准/审查, 基于您所在国家或机构的要求)?

Answer: [NA]

证明: Justification:证明确实是“证明”的意思,但源文本中“Justification”一词在不同上下文中可能有不同指南:

- The answer NA意味着论文既不涉及众包也不涉及涉及人类受试者的研究。
- 根据进行研究的国家不同,任何涉及人类受试者的研究可能都需要IRB批准(或同等批准)。如果您获得了IRB批准,您应在论文中明确说明这一点。
- 我们认识到这些程序在不同机构和地点之间可能会有很大差异,并期望作者遵守NeurIPS伦理守则及其所在机构的指导原则。
- 对于初始提交,如果不适用,请勿包含任何可能破坏匿名性的信息,例如进行审查的机构。